

ドローンを用いた 3 次元再構成における テキスト指示型編集技術の開発

菊地佑太

内容梗概

複数の環境の画像から 3 次元再構成から自由視点画像を得る技術は、近年の AI の発達によって急激に発展している。3D Gaussian Splatting (3DGS) はその代表的な例である。本研究はドローン画像を用いて 3 次元再構成を行った際の課題を解決する。ドローンを用いて屋外撮影を行う場合は時刻とともに、人や物の位置が変化してしまうため、再構成が困難になる。

本研究では映り込んだ不要物体を除去することを考える。提案手法では、テキストで除去する物体を指定することで、自由視点画像から所望の物体を除去することができる。これにより、ドローン画像の 3 次元再構成の活用がしやすくなる。これを実現するために、学習用画像から不要な物体を Segment Anything Model 3 (SAM3) で同定し、学習に使用する画像から削除することで、再構成させる自由視点画像の最適化を試みる。

目次

1	はじめに	3
1.1	本研究の概要	3
1.2	本研究の構成	5
2	研究背景	6
2.1	関連研究	6
2.1.1	3次元再構成技術	6
2.1.2	3次元再構成における評価指標	8
2.1.3	3次元再構成技術を活用するための開発環境の進展	9
2.1.4	セマンティックセグメンテーション	10
2.1.5	映り込みに対応した自由視点画像生成技術	10
2.2	現状の課題	12
2.3	静的な物体を削除して学習させること難しさ	13
3	提案手法	14
3.1	動的物体の検出	14
3.2	静止物体の検出とフィルタリング	16
3.3	不要物の除去	16
4	評価実験と考察	17
4.1	データセット	17
4.2	不要物同定アルゴリズムの評価実験	18
4.3	拡散モデルによる削除部の補完の評価実験	18
4.4	3次元再構成の評価実験	18
5	おわりに	22
5.1	結論	22
5.2	今後の課題	22

1 はじめに

1.1 本研究の概要

3次元再構成とは、複数視点の2次元画像や深度センサデータから、被写体の3次元形状や立体構造をコンピュータ上で復元する技術である。立体視することで、3次元空間での物体の位置や形状を人間がイメージしやすい形で表現することができるため、文化財の保存や3次元マップの作成などに応用されている。

古典的な方法には Structure-from-Motion (SfM) [1] がある。SfM は、複数視点の2次元画像から3次元空間におけるシーンの構造 (Structure) と各画像を撮影したカメラの位置・姿勢 (Motion) を同時に推定する技術である。まず各画像から画像の中で特徴的な点を検出し、異なる画像間に対応する特徴点をマッチングする。次に、対応点の情報を用いてカメラの姿勢や位置、レンズの焦点距離、センサーのサイズといったカメラの内部パラメータと、シーンの構造を推定し、三角測量により3次元点群を復元する。最後に、バンドル調整と呼ばれる最適化手法により、再投影誤差を最小化することで、カメラパラメータと3次元構造を同時に精密化する。SfM は、特別な計測機器を必要とせず、一般的なカメラで撮影した画像のみから3次元モデルを構築できる点が大きな利点であり、フォトグラメトリやデジタルアーカイブ、地図作成などの幅広い分野で活用されている。SfM を実行する場合には COLMAP[2] というソフトウェアが多く用いられている。

ゲームなどのエンターテインメント分野においても3次元再構成が活用されている。例えば、Berezuzeta ら [3] の報告によれば、3次元再構成技術を活用することにより、ゲームにおける背景や人物などのモデリングの工数が大幅に削減できることが示された。また、画像に比べて物体の形をイメージしやすいことから文化財の保存 [4] など、様々な領域で3次元再構成の活用が活発化してきている。

2010年代においては、センサー自らが光やレーザーを照射し、その反射を測定して形状を捉える「Active」な手法、もしくは、一般的なRGBカメラで撮影された画像のみを用いて形状を推定する「Passive」な手法が主流であったが、どちらにも短所があり、高品質な3次元モデルを安価に生成することは困難であった (表1)。

そんな中、近年のAIの発達によって急激に発展したのが、3D Gaussian Splatting (3DGS) [5] である。3DGS は、SfM で得られた祖な点群データを3次元ガウス分布で補完することにより、なめらかに再構成を行うことができる。3DGS の主な利点は、従来の点群ベースの手法と比較して、深度センサーなどの高価な機器を必要とせずRGBカメラの情報だけで再構成が可能でありながら、細部まで高品質な画像を生成できる点である。

近年においてはドローンが比較的安価に購入できるようになったために上空からの

表 1: 能動的手法と受動的手法の比較

	Active な手法	Passive な手法
説明	センサー自体が光やレーザーを発射し、その反射を測定して物体の形状を取得する手法	一般的なカメラで撮影した画像（環境光）のみを用いて物体の形状を推定する手法
主な技術	レーザースキャン、構造化光など	SfM, MVS, フォトグラメトリなど
長所	● 非常に高い精度 ● 純白の石像などのテクスチャが乏しい物体でも形状を取得可能	● 安価な市販カメラで実施可能 ● 持ち運びが容易 ● テクスチャ情報の取得に優れている
短所	● 装置が高価で重い ● 屋外の直射日光下では精度が低下 ● 特定の物体材質（黒や鏡面など）に弱い	● 物体のテクスチャが乏しい場合、特徴点の抽出が困難 ● 照明環境に依存 ● 能動的手法と比較して精度のばらつきが大きい傾向

屋外撮影が容易になった。3DGS は RGB 画像のみで高品質な 3 次元モデルを生成することができるため、深度センサーを搭載していない安価なドローンとの相性が非常によく、屋外撮影においても活用が期待されている。一度に広範囲を撮影することができるため、効率的に広範囲の 3 次元モデルを作成することができる。

ドローンで撮影された画像を一度に学習させる場合は、多くの GPU メモリが必要となるが、それに対する対策も行われている。例えば、Link ら [6] の研究では、大規模なシーンをいくつかに分割して学習させ、それらのモデルを違和感なく統合する手法が提案されている。また、ドローンを用いて屋外撮影をする場合、時刻とともに人や物の位置が変化してしまうため、3 次元再構成が困難になるという課題がある。3DGS は撮影する空間が静止していることが前提であるため、人混みや交通量の多い場所では高品質な再構成が難しい（図 1）。Tang は、DroneSplat という手法を提案しており、動いている物体を学習から除外することでこれらの問題に対処した [7]。

本研究ではドローン撮影時に映り込んだ不要物体を除去することを考える。DroneSplat では、動いている物体を学習から除外することでこれらの問題に対処した。しかし、ドローンの撮影時には停車中の車など、静止していても不要なものが写り込んでしまうことがある。静止している不要物体を削除する場合は 3 次元再構成を行った後に人の手で削除する必要があるが、工数がかかるという問題点がある。また、文化財保存やゲームなど使う用途によって何を「不要」とするかは様々であり、自動化が難しいと言う問題がある。以上より、より簡単に指定した不要物体を自動で削除して



図 1: 撮影中に走行中の車が写り込んでしまった場合の 3 次元再構成の結果

再構成する技術が求められている。

本研究では、ユーザが不要だと設定した物体をテキストで指定し、動いている物体と同時に再構成モデルから削除する仕組みを提案する。セマンティックセグメンテーションモデルの Segment Anything Model 3 (SAM3)[8] にユーザが不要であると設定した物体をテキストで入力し、学習用画像内から該当する物体を同定する。不要物体であると判断された領域は拡散モデルである LaMa[?] により補完することで、自然な 3 次元モデルを得ることができる。また、Dronsplat[7] の技術を用いて 3 次元再構成に悪影響を与える動いている物体も同時に削除する。

結果として、DroneSplat と同等の再構成精度を保ちながら、静止している不要物体も自然言語により再構成することが可能となった。また、DroneSplat で検出しきれなかった不要物体も検出できるようになった。以上より、本研究はドローン撮影時に映り込んだ不要物体を除去することができ、ドローンで撮影した画像を手軽に 3 次元再構成することができ、工数を削減することができる。

1.2 本研究の構成

本論文は次のように構成される。第二章では主要な 3 次元再構成に触れつつ、現状の課題を述べる。第三章では提案手法を説明する。不要物を同定するアルゴリズムと、拡散モデルによる削除部の補完を行う手法を説明する。第四章では評価実験と考察を行う。

2 研究背景

2.1 関連研究

2.1.1 3次元再構成技術

3次元再構成とは、RGB 画像や、深度情報などを用いて 3 次元空間における物体の形状をモデリングする技術である。3 次元モデルを表現する方法としては、主にメッシュや点群などがある（図 2）。




図 2: 3次元モデルの表現方法

Structure from Motion (SfM)[1] は点群データを用いた 3 次元再構成の代表的な例である。SfM は、同一シーンを異なる視点から撮影した複数の画像から、3 次元空間におけるシーンの構造 (Structure) と各画像を撮影したカメラの位置・姿勢 (Motion) を同時に推定する。処理の流れとしては、まず各画像から特徴点検出し、異なる画像間で対応する特徴点をマッチングする。次に、対応点の情報を用いてカメラの内部パラメータと外部パラメータ (位置・姿勢) を推定し、三角測量により 3 次元点群を復元する。最後に、バンドル調整と呼ばれる最適化手法により、再投影誤差を最小化することで、カメラパラメータと 3 次元構造を同時に精密化する。SfM は、特別な計測機器を必要とせず、一般的なカメラで撮影した画像のみから 3 次元モデルを構築できる点が大きな利点であり、フォトグラメトリやデジタルアーカイブ、地図作成などの幅広い分野で活用されている。

そのほかにも、ニューラルネットワークを用いて 3 次元空間を表現する手法がある。

髪の毛や細かな草木、あるいは煙のような境界が曖昧なものをメッシュで表現するのはほぼ不可能であった。NeRF[9] はそのような複雑な形状を高精細に表現することができる。NeRF はニューラルネットワークを用いて 3 次元空間を表現する技術である。同一シーンを異なる視点から撮影した複数の画像とカメラパラメータを用いて学習し、学習用画像とニューラルネットワークが出力する画像の誤差が小さくなるように学習することで、3 次元表現を獲得する。また、ニューラルネットワークは学習に用いた角度以外の任意の視点から高品質な自由視点画像を生成することができる。一方で、レンダリング時に各ピクセルごとにニューラルネットワークの推論が必要となるため、レンダリング速度が非常に遅く、リアルタイムでの自由視点ナビゲーションが困難であるという課題がある。

このレンダリングの遅さを解消したのが、2023 年に発表されたのが Kerbl らによって提案された 3D Gaussian Splatting (3DGS) [5] である。学習を進めながら生成の品質を高める点では NeRF と同一であるが、3 次元空間を 3 次元ガウス分布の集合として表現することが特徴である。各ガウス分布は、位置、共分散行列（形状と向き）、不透明度、そして球状調和関数に基づく色情報をパラメータとして持つ。ポイントベースの α （アルファ）ブレンディングと NeRF スタイルのボリュームレンダリングは、本質的に同じ画像生成モデルを共有している。具体的には、ある光線（レイ）に沿った色 C は、以下のボリュームレンダリングの式で与えられる：

$$C = \sum_{i=1}^N T_i (1 - \exp(-\sigma_i \delta_i)) c_i \quad \text{ここで} \quad T_i = \exp\left(-\sum_{j=1}^{i-1} \sigma_j \delta_j\right) \quad (1)$$

ここで、密度 σ 、透過率 T 、および色 c のサンプルが、間隔 δ_i で光線に沿って取得される。これは次のように書き換えることができる：

$$C = \sum_{i=1}^N T_i \alpha_i c_i \quad (2)$$

ただし、 $\alpha_i = (1 - \exp(-\sigma_i \delta_i))$ および $T_i = \prod_{j=1}^{i-1} (1 - \alpha_j)$ である。典型的なニューラルポイントベースのアプローチは、ピクセルに重なる N 個の順序付けられた点をブレンディングすることで、ピクセルの色 C を計算する：

$$C = \sum_{i \in N} c_i \alpha_i \prod_{j=1}^{i-1} (1 - \alpha_j) \quad (3)$$

ここで、 c_i は各点の色であり、 α_i は学習された「点ごとの不透明度」に、共分散 Σ を

持つ 2 次元ガウス関数を評価して得られる値を掛け合わせることで求められる。

自由視点画像を生成する際、これらの 3D ガウス分布をカメラ平面にスプラッティング（射影）し、ハードウェアが高速に処理できるラスタライズ技術を利用してピクセル単位の色を合成する。これにより、NeRF と比較して画質を維持しつつ、学習時間およびレンダリング速度を大幅に短縮し、リアルタイムでの自由視点ナビゲーションを可能にした [5]。本研究の提案手法も、この高速な 3DGS を基盤技術として採用している。

2.1.2 3次元再構成における評価指標

3次元再構成の品質を評価するための評価指標を紹介する。PSNR（Peak Signal-to-Noise Ratio）は、画像のピーク信号対雑音比を表す指標であり、単位は dB である。PSNR は以下の式で計算される：

$$\text{PSNR} = 10 \log_{10} \frac{\text{MAX}_I^2}{\text{MSE}} \quad (4)$$

ここで、 MAX_I は画像の最大画素値、MSE は平均二乗誤差である。PSNR が高いほど、再構成画像の品質が高いことを示す。

SSIM（Structural Similarity Index）は、画像の構造的類似度を評価する指標であり、0 から 1 の範囲の値を取る。SSIM は輝度、コントラスト、構造の 3 つの要素を組み合わせて計算される：

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + C_1)(2\sigma_{xy} + C_2)}{(\mu_x^2 + \mu_y^2 + C_1)(\sigma_x^2 + \sigma_y^2 + C_2)} \quad (5)$$

ここで、 μ_x と μ_y はそれぞれ画像 x と y の平均値、 σ_x^2 と σ_y^2 はそれぞれの分散、 σ_{xy} は共分散、 C_1 と C_2 は安定化のための定数である。SSIM が 1 に近いほど、再構成画像と正解画像の構造的類似度が高いことを示す。

LPIPS（Learned Perceptual Image Patch Similarity）は、深層学習モデルを用いて画像の知覚的類似度を評価する指標であり、0 に近いほど知覚的に類似していることを示す。LPIPS は、事前学習済みの CNN（Convolutional Neural Network）の特徴量空間における距離を計算することで、人間の知覚により近い評価を実現する。LPIPS は以下の式で計算される：

$$\text{LPIPS}(x, y) = \sum_l \frac{1}{H_l W_l} \sum_{h,w} \|\hat{y}_l^{(h,w)} - \hat{x}_l^{(h,w)}\|_2^2 \quad (6)$$

ここで、 $\hat{x}_l^{(h,w)}$ と $\hat{y}_l^{(h,w)}$ はそれぞれ画像 x と y を l 番目の層に通した後の特徴量マップの (h, w) 位置の正規化された特徴量ベクトル、 H_l と W_l は特徴量マップの高さと幅である。これらの指標を組み合わせることで、画素レベルの誤差から知覚的品質まで、異なる観点から包括的に画像品質を評価することができる。PSNR は画素値の誤差に基づく低レベルの評価を、SSIM は構造的類似度に基づく中レベルの評価を、LPIPS は深層学習モデルの特徴量空間に基づく高レベルの知覚的評価をそれぞれ提供する。これにより、単一の指標では捉えきれない画像品質の側面を多角的に評価し、より信頼性の高い性能比較が可能となる。

2.1.3 3次元再構成技術を活用するための開発環境の進展

3次元再構成技術の実用化に向けて、研究者や開発者が容易にこれらの技術を活用できる開発環境の整備が進められている。NeRFStudio[10] は、NeRF や 3DGS などの3次元再構成技術を統合的に扱うためのオープンソースフレームワークである。NeRFStudio は、データの前処理から学習、レンダリング、可視化まで、3次元再構成のワークフロー全体をサポートする統合的な開発環境を提供している。これにより、研究者は複雑な実装の詳細に煩わされることなく、様々な3次元再構成手法を比較検討し、新たな手法の開発に集中することができる。また、NeRFStudio はモジュール化された設計により、新しい手法の追加や既存手法の拡張を容易にし、3次元再構成技術の発展を加速させている。

Sample Image

図 3: NeRFStudio の利用例

2.1.4 セマンティックセグメンテーション

セマンティックセグメンテーションは、画像の各ピクセルをなんらかの意味を持った領域に分割する技術のことである。一つの画像に対して一つのラベルを付与する画像分類問題や、画像内の物体を認識し、矩形で過酷む物体検出と比べると、セマンティックセグメンテーションは画像中のピクセルに対してラベルを付与することで、より細かい粒度での物体の分割を行うことができる（図 4）。SAM2[11] はセマンティックセグメンテーションの代表的な例である。SAM2 は、従来のセマンティックセグメンテーション手法が特定の物体クラスに限定されていたり、動画シーケンスへの対応が困難であったりした課題を克服した画期的な手法である。SAM2 の最大の特徴は、大規模データセットで学習された汎用的なセグメンテーションモデルを持ち、事前に学習した物体クラス以外の物体もセグメンテーションできる点である。さらに、画像だけでなく動画シーケンスにも対応し、時系列情報を活用することで、より一貫性のあるセグメンテーション結果を生成することができる。また、ユーザーからの点や矩形、テキストなどの多様な入力形式を受け付けることができる点も、従来手法と比較して大きな進歩であった。




図 4: コンピュータビジョンタスクの比較

2.1.5 映り込みに対応した自由視点画像生成技術

Tang らによって提案された DroneSplat[7] は、ドローンを用いた大規模な屋外環境における動的物体への耐性を高めた 3DGS[5] の拡張手法である。本手法は、Segment Anything Model v2 (SAM2) [11] を用いた適応的な動的物体マスキング (Adaptive dynamic-object masking) を特徴とする。

DroneSplat の学習プロセスは、2 段階の学習フェーズから構成される。第 1 段階 (Pre-training) では、SAM2 を用いて各学習画像 I_k ($k = 1, \dots, N$ はフレーム番号)

からインスタンスレベルのセグメンテーションマスク $\mathcal{M}_k = \{M_k^1, M_k^2, \dots, M_k^{S_k}\}$ を取得する．ここで、 S_k はフレーム k におけるセグメント数である．

次に、3DGS の学習において、動的物体を含むセグメントを段階的に除外する適応的マスクングを適用する．具体的には、学習 iteration t における損失関数 $\mathcal{L}_t$ を以下のように定義する：

$$\mathcal{L}_t = \sum_{k=1}^N \sum_{p \in \mathcal{P}_k} w_t(p) \cdot \ell(\hat{I}_k(p), I_k(p)) \quad (7)$$

ここで、 $\hat{I}_k(p)$ はフレーム k のピクセル p におけるレンダリング結果、 $I_k(p)$ は正解画像、 $\ell(\cdot, \cdot)$ は L1 損失と SSIM 損失の組み合わせ、 $\mathcal{P}_k$ はフレーム k の全ピクセル集合である．重み $w_t(p)$ は、iteration t におけるピクセル p の動的物体マスク $\mathcal{M}_t^{\text{dynamic}}(p)$ に基づいて以下のように決定される：

$$w_t(p) = \begin{cases} 0 & \text{if } \mathcal{M}_t^{\text{dynamic}}(p) = 1 \\ 1 & \text{otherwise} \end{cases} \quad (8)$$

動的物体マスク $\mathcal{M}_t^{\text{dynamic}}$ は、各 iteration において更新される．初期 iteration では全セグメントを学習対象とするが、学習が進むにつれて、複数フレーム間で一貫性のない再構成誤差を示すセグメントを動的物体として同定し、段階的に除外する．具体的には、セグメント M_k^i の動的度合い D_k を以下の式で計算する：

$$D_k = \frac{1}{|M_k^i|} \sum_{p \in M_k^i} \max_{q \in \mathcal{P}_k} \ell(\hat{I}_k(q), I_k(q)) \quad (9)$$

ここで、 $|M_k^i|$ はセグメント M_k^i の画素数である．動的度合いが閾値 τ_{dynamic} を超えるセグメントは動的物体として判定され、その後の学習から除外される．第 2 段階 (Main training) では、第 1 段階で得られた動的物体マスクを用いて、動的物体を除外した画像に対して 3DGS を再学習する．これにより、動的な不要物体を考慮しない高品質な 3D シーン再構成が可能となる．評価実験では、従来の 3DGS に対し、ドローン撮影時の再構成精度および視点合成品質の両面で有意な改善を示しつつ、GPU 上でのリアルタイムレンダリング性能も維持できることが報告されている (図 5)．



(a) 3DGS[5] で作成
車が動いている場面を表現できない



(b) DroneSplat[7] で生成
動体を無視して表現できる

図 5: 動的なシーンにおける自由視点画像生成の例

2.2 現状の課題

自由視点画像生成技術の研究においては、以下の 4 つの領域が研究の中心となっている：

- (1) 高精細に再構成する
- (2) 計算量を削減する
- (3) レンダリング速度を高速化する
- (4) 人や物の動きへ対応する

これらを実用レベルで実現できるモデルが理想である。本研究は、(4) 人や物の動きへ対応するための研究である。現状、多くの研究は (1)～(3) の領域で進められている。例えば、3D Gaussian Splatting[5] は高精細な再構成と高速なレンダリングを実現し、NeRF[9] は高品質な 3 次元再構成を可能にした。しかし、これらの手法は動的な物体が含まれるシーンにおいて、再構成精度の低下やアーティファクトの発生などの問題を抱えている。一方、(4) 人や物の動きへ対応する研究は、動的物体の検出や除去、動的なシーンの再構成など、複雑な課題を伴うため、実用化まで至っている手法は限られている。特に、ドローンや屋外環境での撮影においては、動的な物体（人、車両など）や不要な静止物体（看板、電柱など）が写り込むことが多く、これらを適切に処理することが実用化の鍵となる。

本研究では、(4) の対応策として映り込みに対応した自由視点画像生成技術において、不要物を同定することを考える。本研究における不要物とは以下の 2 つである：

- (1) 動的な物体
- (2) 静止しているがユーザが不要と判断した物体


2.3 静的な物体を削除して学習させること難しさ

動的な物体への対応は，DroneSplat[7]で行われている．しかし，静止していてもユーザが不要と判断した物体を同定することはできない．また，DroneSplatにおける動的な物体の検出も学習画像によって間違いが起こることも多い（図 6）．具体的には，動的物体の検出漏れや，静止している背景の誤検出などが発生し，完全な不要物の除去が困難である．さらに，静止している不要物体を削除する際には，単純にマスクで物体を除去するだけでは不十分であるという問題がある．例えば，ある時刻において駐車場に停車中の車が写っている画像と，別の時刻において同じ場所に車が存在しない画像がある場合，単純にマスクで車を削除すると，その場所の背景情報（道路や駐車場の表面）が欠落してしまい，データが虫食い状態になってしまう．このような欠落した領域をそのまま学習に使用すると，3次元再構成の精度が低下し，アーティファクトが発生する原因となる．この問題を解決するためには，マスクで削除した領域を適切に補完する必要がある．拡散モデルを用いた画像インペインティング技術は，周囲の文脈情報を活用して，欠落した領域を自然に補完することができる．拡散モデルは，ノイズから画像を生成する過程で，周囲の画素情報やシーンの構造を学習しており，これにより，削除された物体の背後にある背景を推論して補完することが可能である．したがって，静止している不要物体を削除した後，拡散モデルによる穴埋め処理を行うことで，完全な背景情報を持つ画像を生成し，高品質な3次元再構成を実現できる．

さらに，マップ作成や3Dモデリングなどの実用応用においては，不要物を削除する前処理に多くの時間と労力を要するのが現状である．従来の手法では，手動での不要物の指定や，複雑な前処理パイプラインの構築が必要であり，実用化の障壁となっている．本研究が結実することで，3Dモデリングの工数が短縮され，前処理の必要がない，世界に類を見ない実用的な自由視点画像生成モデルとなることが期待される．



(a) 学習用画像



(b) DroneSplat[7]によって動いていると判定された物体

図 6: DroneSplat[7]によって動いていると判定された物体を（図 6b）に示す．動的な物体の物体漏れが発生する．また，動いていないはずの背景も動いていると誤判定されるケースもある．

3 提案手法

本手法では, 3DGS[5] の学習において, 動的物体と静止物体を区別して不要物を同定する. 動的物体は学習中の損失情報から検出し, 静止物体は事前学習済みのセグメンテーションモデルを用いて検出する. 両者の情報を統合することで, より包括的な不要物同定を実現する. 本手法の学習の流れを以下に示す:

1. **動的物体の検出:** 元の画像データセットを用いて DroneSplat を学習し, 動的物体のマスクを取得する (3.1 節).
2. **静止物体の検出とフィルタリング:** SAM3 の検出結果と動的物体のマスクを比較し, 重複する物体を除外する (3.2 節).
3. **不要物の除去:** フィルタリング後の静止物体マスクに対して LaMa を適用し, 不要物を除去した画像を生成する (3.3 節).
4. **再学習:** 不要物の除去後の画像を用いて DroneSplat を再学習し, 最終的な 3D シーン再構成を行う.

この流れにより, 動的物体と静止物体の両方を効果的に除去し, 高品質な 3D シーン再構成を実現する (図 7).

3.1 動的物体の検出

動的物体は, 3D Gaussian Splatting[5] の学習過程において, 複数フレーム間で一貫性のない再構成誤差を示す領域として検出される. 本手法では, DroneSplat[7] の学習アルゴリズムを拡張し, 各フレームにおけるインスタンスレベルの損失分布を分析することで動的物体を同定する.

具体的には, 学習開始から一定の iteration (本実験では 500 iteration) 経過後, 各フレームのレンダリング結果と正解画像との間の L1 損失および SSIM 損失を計算する. これらの損失を正規化し, 以下の式で統合損失を算出する:

$$L_{combined} = \frac{4 \cdot L_{L1}^{norm} + L_{SSIM}^{norm}}{5} \quad (10)$$

ここで, L_{L1}^{norm} および L_{SSIM}^{norm} は, それぞれ L1 損失と SSIM 損失を 0-1 の範囲に正規化した値である.

次に, 各フレームに与えられたインスタンスセグメンテーションマスクを用いて, イ




図 7: 提案手法の流れ図

インスタンス単位での損失を集計する．インスタンス i の損失 L_i は，以下の式で計算される：

$$L_i = \frac{\sum_{p \in M_i} L_{combined}(p)}{|M_i|} \quad (11)$$

ここで， M_i はインスタンス i のマスク領域， $|M_i|$ はその画素数である．

各インスタンスの損失値をヒートマップとして可視化し，動的閾値 $T_{dynamic}$ を以下の式で決定する：

$$T_{dynamic} = \mu + \sigma + \alpha \cdot \sigma \cdot \frac{I_{max} - I_{current}}{I_{max}} \quad (12)$$

ここで， μ と σ はヒートマップの平均値と標準偏差， $I_{current}$ と I_{max} は現在の iteration と最大 iteration， α は調整パラメータである．この閾値により，学習の進行に応じて動的物体の検出感度を調整する．

損失値が閾値を超えるインスタンスは動的物体として判定され，そのマスクが除外

対象として記録される．学習の最終 iteration において，すべての学習フレームに対する除外マスクを保存する．

3.2 静止物体の検出とフィルタリング

静止物体の検出には，Segment Anything Model 3 (SAM3)[8] を用いる．SAM3 は，テキストプロンプト（本実験では”car”）に基づいて動画シーケンス全体から対象物体を追跡・セグメンテーションする．各フレームにおいて，検出された物体のマスク，バウンディングボックス，信頼度スコアが出力される．しかし，SAM3 は動的・静止を区別せずにすべての不要物体を検出するため，動的物体と静止物体を区別する必要がある．本手法では，3.1 節で検出された動的物体のマスクと SAM3 の検出結果を比較し，重複する物体を除外する．具体的には，SAM3 で検出された各物体 o_j について，そのマスク $M_{SAM3}(o_j)$ と動的物体のマスク $M_{dynamic}$ との重複率 $R_{overlap}$ を以下の式で計算する：

$$R_{overlap}(o_j) = \frac{|M_{SAM3}(o_j) \cap M_{dynamic}|}{|M_{SAM3}(o_j)|} \quad (13)$$

ここで， $|M_{SAM3}(o_j) \cap M_{dynamic}|$ は重複領域の画素数， $|M_{SAM3}(o_j)|$ は SAM3 で検出された物体の総画素数である．重複率が閾値 $T_{overlap}$ （本実験では 0.5）を超える場合，その物体は動的物体として既に検出されていると判定し，SAM3 の検出結果から除外する．これにより，静止物体のみが残る．

3.3 不要物の除去

同定された不要物（動的物体および静止物体）は，画像インペインティング技術を用いて除去する．本手法では，Large Mask Inpainting (LaMa)[12] を使用する．静止物体のマスクは，境界の拡張処理を適用してからインペインティングを行う．具体的には，形態学的な膨張処理（カーネルサイズ 15 ピクセル）により，マスクの境界を拡張し，より自然な補完結果を得る．各物体は順次処理され，最終的にすべての不要物が除去された画像が生成される．この画像を 3D Gaussian Splatting の学習データとして使用することで，動的物体の影響を受けない高品質な 3D シーン再構成が可能となる．なお，本研究では SAM2[11] と LaMa を統合した InpaintAnything[13] を使用する．

4 評価実験と考察

4.1 データセット

本実験のため，歩行中の人と静止している人の両方が映っている学習用画像を取得した．撮影には DJI 社の DJI Mini 4 Pro を使用した．実験に際しては本校の学生と教員合わせて 5 名の被験者に依頼し撮影に協力してもらった．撮影は静止している人を中心として半円を描くような軌道で撮影を行った．画像データの詳細を表 2 に示した．

表 2: データセットの詳細

項目	Aoba_001	Simingshan
画像数	44 枚	24 枚
解像度	1920×1080	1920×1080
撮影デバイス	DJI Mini 4 Pro	ドローン
撮影方法	静止している人を中心とした半円軌道	交通量の多い道路をドローンで撮影
特徴	歩行中の人と静止している人の両方が映っている	駐車中の車両と走行中の車両の両方を含む

本実験で使用した Aoba_001 データセットのサンプル画像を図 8 に示した．評価用のデータセットとして，DroneSplat[7] で使用されたデータセットを用いた (図 9)．本データセットは交通量の多い道路をドローンで撮影したものであり，駐車中の車両と走行中の車両の両方を含んでいる．様々な画角から撮影されているが，ある時刻において写り込んでいる車両が他の時刻では画面内に映っていない場合もある．データは時系列ごとに並べられているわけではなく，独立した時刻の画像を集めたものである．



図 8: データセット Aoba_001

4.2 不要物同定アルゴリズムの評価実験

次に, SAM3 を用いた不要物同定を評価した. Simingshan データセットを用いて, 各画像について学習した際にどれくらい多くの車を検出できているかを数え上げて評価した結果を表 3 に示した. 評価には, DroneSplat, SAM3 のみ, および提案手法の 3 手法を比較した. なお, DroneSplat は停車中の車両を検出するアルゴリズムが実装されていないため, 停車中の車両の検出数は記載していない. 評価結果から, 走行中の車両の検出において, 提案手法は平均 97.4% の検出率を達成し, DroneSplat (平均 58.9%) および SAM3 のみ (平均 74.4%) と比較して高い検出率を示した. 停車中の車両の検出において, 提案手法は 100% の検出率を達成し, SAM3 のみ (平均 78.3%) と比較して高い検出率を示した. 提案手法は動的物体との重複を適切に除外することで, より正確な不要物同定を実現した.

4.3 拡散モデルによる削除部の補完の評価実験

映り込みに対応した自由視点画像生成技術の DroneSplat[7] においては, 動的物体を学習から削除している. 一方, 本手法では静止物体を削除した後に拡散モデルによるインペインティング処理を行うことで, 欠落した領域を適切に補完する. インペインティング処理の効果を評価するため, 不要物体を削除した画像とインペインティング処理後の画像を比較した (図 10). インペインティング処理により, 削除された物体の背後にある背景が自然に補完され, 視覚的に不自然な箇所が大幅に減少したことが確認できる.

4.4 3次元再構成の評価実験

3次元再構成の品質を定量的に評価するため, Simingshan データセットを用いて各手法の性能を比較した. 評価には, PSNR, SSIM, LPIPS の 3 つの評価指標を使



図 9: データセット Simingshan

表 3: Simingshan データセットにおける各画像の車検出数と正解率

画像 番号	走行中の車両				停車中の車両			
	正解数	検出数 (検出率)			正解数	検出数 (検出率)		
		DroneSplat	SAM3 のみ	提案手法		DroneSplat	SAM3 のみ	提案手法
001	3	2 (66.7%)	2 (66.7%)	3 (100.0%)	2	-	1 (50.0%)	2 (100.0%)
002	4	2 (50.0%)	3 (75.0%)	4 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
003	2	1 (50.0%)	1 (50.0%)	2 (100.0%)	2	-	1 (50.0%)	2 (100.0%)
004	4	2 (50.0%)	3 (75.0%)	3 (75.0%)	2	-	2 (100.0%)	2 (100.0%)
005	5	3 (60.0%)	4 (80.0%)	5 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
006	3	2 (66.7%)	2 (66.7%)	3 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
007	6	4 (66.7%)	5 (83.3%)	6 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
008	4	2 (50.0%)	3 (75.0%)	4 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
009	5	3 (60.0%)	4 (80.0%)	5 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
010	2	1 (50.0%)	1 (50.0%)	2 (100.0%)	2	-	1 (50.0%)	2 (100.0%)
011	5	3 (60.0%)	4 (80.0%)	4 (80.0%)	3	-	2 (66.7%)	3 (100.0%)
012	3	2 (66.7%)	2 (66.7%)	3 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
013	4	2 (50.0%)	3 (75.0%)	4 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
014	4	2 (50.0%)	3 (75.0%)	4 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
015	6	4 (66.7%)	5 (83.3%)	6 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
016	3	2 (66.7%)	2 (66.7%)	3 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
017	4	2 (50.0%)	3 (75.0%)	4 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
018	5	3 (60.0%)	4 (80.0%)	5 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
019	2	1 (50.0%)	1 (50.0%)	2 (100.0%)	2	-	1 (50.0%)	2 (100.0%)
020	4	2 (50.0%)	3 (75.0%)	4 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
021	3	2 (66.7%)	2 (66.7%)	3 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
022	4	2 (50.0%)	3 (75.0%)	4 (100.0%)	2	-	2 (100.0%)	2 (100.0%)
023	5	3 (60.0%)	4 (80.0%)	5 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
024	4	2 (50.0%)	3 (75.0%)	4 (100.0%)	3	-	2 (66.7%)	3 (100.0%)
平均	3.9	2.3 (58.9%)	2.9 (74.4%)	3.8 (97.4%)	2.3	-	1.8 (78.3%)	2.3 (100.0%)

用した. NeRF と 3DGS の評価は, NeRFStudio[10] 内のモデルを利用して実施した. 一方, DroneSplat と提案手法の評価は, DroneSplat が提供する評価プログラムを用いて検証した. 評価結果を表 4 に示す.

DroneSplat と提案手法は, 従来手法である NeRF や 3DGS と比較して劇的な性能向上を達成した. NeRF (PSNR: 19.07 dB, SSIM: 0.417, LPIPS: 0.267) や 3DGS (PSNR: 19.68 dB, SSIM: 0.476, LPIPS: 0.254) と比較して, DroneSplat と提案手法は PSNR で約 3 dB (約 15-16%), SSIM で約 60%, LPIPS で約 40% の劇的な改善を示している.

さらに重要な点として, 提案手法は動的シーン (Simingshan データセット) において, 静止シーンを対象とした先行研究 [5] と遜色ない性能を達成している. 表 5 に, 3DGS の論文 [5] で報告されている Mip-NeRF360 データセット (静止シーン) における各手法の評価結果を示す. 提案手法は動的シーンにおいて PSNR 22.79 dB,




図 10: 拡散モデルによるインペインティング処理の前後比較

SSIM 0.757, LPIPS 0.155 を達成しており、静止シーンでの結果と比較すると、特に LPIPS では Mip-NeRF360 (0.237) や 3DGS (0.279) を上回る性能を示している。SSIM についても 0.757 という値は、静止シーンでの 3DGS (0.770) に近い値を達成しており、動的シーンでも静止シーンと遜色ない構造的類似性を実現できている。これらの結果は、提案手法が動的シーンという従来手法が困難としていた条件下でも、静止シーンを対象とした先行研究と同等の高品質な 3 次元再構成を実現できて

表 4: Simingshan データセットにおける各手法の性能比較

Method	Simingshan		
	SSIM↑	PSNR↑	LPIPS↓
NeRF[9]	0.417	19.07	0.267
3DGS[5]	0.476	19.68	0.254
DroneSplat[7]	0.759	22.76	0.152
Ours	0.757	22.79	0.155

表 5: Mip-NeRF360 データセットにおける各手法の性能比較 [5]

Method	SSIM↑	PSNR↑	LPIPS↓
Plenoxels[14]	0.626	23.08	0.463
INGP-Base	0.671	25.30	0.371
INGP-Big	0.699	25.59	0.331
M-NeRF360[15]	0.792	27.69	0.237
3DGS[5]	0.770	25.60	0.279

いることを明確に示している。提案手法と DroneSplat の比較において、提案手法は PSNR で最高値 (22.79 dB) を達成し、DroneSplat (22.76 dB) と同等の性能を示した。SSIM と LPIPS においても、提案手法 (SSIM: 0.757, LPIPS: 0.155) は DroneSplat (SSIM: 0.759, LPIPS: 0.152) とわずかな差であり、実質的に同等の性能を示した。これは、提案手法が DroneSplat と遜色なく 3 次元再構成を実現できていることを示しており、不要物除去という追加機能を提供しながらも、再構成品質を維持できていることを意味する。

3 つの評価指標は強い正の相関を示しており、各手法の性能が全指標で一貫して評価されていることが確認された。




図 11: DroneSplat における元画像とインペインティング処理後の画像の損失比較

5 おわりに

おわりに...

5.1 結論

5.2 今後の課題

課題は

参考文献

- [1] Noah Snavely, Steven M. Seitz, and Richard Szeliski. Photo tourism: Exploring photo collections in 3d. In *ACM SIGGRAPH*, pages 835–846, 2006.
- [2] Johannes L Schönberger and Jan-Michael Frahm. Structure-from-motion revisited. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 4104–4113, 2016.
- [3] Santiago Berrezueta-Guzman, Andrei Koshelev, and Stefan Wagner. From reality to virtual worlds: The role of photogrammetry in game development. In *2025 IEEE Gaming, Entertainment, and Media Conference (GEM)*, pages 1–6, 2025.
- [4] Leonardo Gomes, Olga Regina Pereira Bellon, and Luciano Silva. 3d reconstruction methods for digital preservation of cultural heritage: A survey. *Pattern Recognition Letters*, 50:3–14, 2014.
- [5] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4), July 2023.
- [6] Jiaqi Lin, Zhihao Li, Xiao Tang, Jianzhuang Liu, Shiyong Liu, Jiayue Liu, Yangdi Lu, Xiaofei Wu, Songcen Xu, Youliang Yan, and Wenming Yang. Vastgaussian: Vast 3d gaussians for large scene reconstruction. In *CVPR*, 2024.
- [7] Jiadong Tang, Yu Gao, Dianyi Yang, Liqi Yan, Yufeng Yue, and Yi Yang. Dronesplat: 3d gaussian splatting for robust 3d reconstruction from in-the-wild drone imagery, 2025.
- [8] Nicolas Carion, Laura Gustafson, Yuan-Ting Hu, Shoubhik Debnath, Ronghang Hu, Didac Suris, Chaitanya Ryali, Kalyan Vasudev Alwala, Haitham Khedr, Andrew Huang, Jie Lei, Tengyu Ma, Baishan Guo, Arpit Kalla, Markus Marks, Joseph Greer, Meng Wang, Peize Sun, Roman Rädle, Triantafyllos Afouras, Effrosyni Mavroudi, Katherine Xu, Tsung-Han Wu, Yu Zhou, Liliane Momeni, Rishi Hazra, Shuangrui Ding, Sagar Vaze, Francois Porcher, Feng Li, Siyuan Li, Aishwarya Kamath, Ho Kei Cheng, Piotr Dollár, Nikhila Ravi, Kate Saenko, Pengchuan Zhang, and Christoph Feichtenhofer. Sam 3: Segment anything with concepts, 2025.
- [9] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Bar-

- ron, Ravi Ramamoorthi, and Ren Ng. Nerf: Representing scenes as neural radiance fields for view synthesis, 2020.
- [10] Matthew Tancik, Ethan Weber, Evonne Ng, Ruilong Li, Brent Yi, Justin Kerr, Terrance Wang, Alexander Kristoffersen, Jake Austin, Kamyar Salahi, Abhik Ahuja, David McAllister, and Angjoo Kanazawa. Nerf-studio: A modular framework for neural radiance field development. In *ACM SIGGRAPH 2023 Conference Proceedings*, SIGGRAPH '23, 2023.
 - [11] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. Sam 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
 - [12] Roman Suvorov, Elizaveta Logacheva, Anton Mashikhin, Anastasia Remizova, Arsenii Ashukha, Aleksei Silvestrov, Naejin Kong, Harshith Goka, Kiwoong Park, and Victor Lempitsky. Resolution-robust large mask inpainting with fourier convolutions. *arXiv preprint arXiv:2109.07161*, 2021.
 - [13] Tao Yu, Runseng Feng, Ruoyu Feng, Jinming Liu, Xin Jin, Wenjun Zeng, and Zhibo Chen. Inpaint anything: Segment anything meets image inpainting. *arXiv preprint arXiv:2304.06790*, 2023.
 - [14] Sara Fridovich-Keil and Alex Yu, Matthew Tancik, Qinhong Chen, Benjamin Recht, and Angjoo Kanazawa. Plenoxels: Radiance fields without neural networks. In *CVPR*, 2022.
 - [15] Jonathan T. Barron, Ben Mildenhall, Dor Verbin, Pratul P. Srinivasan, and Peter Hedman. Mip-nerf 360: Unbounded anti-aliased neural radiance fields. *CVPR*, 2022.