

ドローンを用いた 3 次元再構成における テキスト指示型編集技術の開発

菊地佑太

内容梗概

環境の画像から自由視点画像を得る技術は、近年の AI の発達によって急激に発展している。3D Gaussian Splatting (3DGS) はその代表的な例である。ドローンを用いて屋外撮影をする場合の固有の課題が発生するが、それらに対する先行研究もある。例えば、時刻とともに人や物の位置が変化してしまうため、3 次元再構成が困難になるが DroneSplat ではそれに対する対応が行われている。

本研究では映り込んだ不要物体を除去することを考える。提案手法では、テキストで除去する物体を指定することで、自由視点画像から所望の物体を除去することができる。これにより、ドローン画像の 3 次元再構成の活用がしやすくなる。これを実現するために、学習用画像から不要な物体を CLIP 等のマルチモーダル画像分類器で同定し、学習に使用する画像から削除することで、再構成させる自由視点画像の最適化を試みる。

目次

1	はじめに	3
1.1	本研究の概要	3
1.2	本研究の構成	3
2	研究背景	4
2.1	関連研究	4
2.1.1	3次元再構成技術	4
2.1.2	セマンティックセグメンテーション	5
2.1.3	映り込みに対応した自由視点画像生成技術	6
2.2	現状の課題	8
3	提案手法	9
3.1	不要物同定アルゴリズム	9
3.1.1	動的オブジェクトの検出	10
3.1.2	静止オブジェクトの検出とフィルタリング	11
3.1.3	不要物の除去	12
3.2	拡散モデルによる削除部の補完	12
4	評価実験と考察	13
4.1	データセット	13
4.2	不要物同定アルゴリズムの評価実験	13
4.2.1	SAM2 と CLIP による不要物同定	13
4.2.2	SAM3 による不要物同定	13
4.3	拡散モデルによる削除部の補完の評価実験	13
4.3.1	学習用画像中に一貫性を持たせた拡散モデルの有効性の検証	13
4.3.2	動的な不要物の除去における拡散モデルの必要性の検証	13
5	おわりに	14
5.1	結論	14
5.2	今後の課題	14

1 はじめに

1.1 本研究の概要

環境の画像から自由視点画像を得る技術は、近年の AI の発達によって急激に発展している．3D Gaussian Splatting (3DGS) [1] はその代表的な例である．ドローンを用いて屋外撮影をする場合の固有の課題が発生するが、それらに対する先行研究もある．例えば、時刻とともに人や物の位置が変化してしまうため、3次元再構成が困難になるが（図 1-a）、DroneSplat[2] ではそれに対する対応が行われている（図 1-b）．

本研究では映り込んだ不要物体を除去することを考える．提案手法では、テキストで除去する物体を指定することで、自由視点画像から所望の物体を除去することができる．これにより、ドローン画像の3次元再構成の活用がしやすくなる．これを実現するために、学習用画像から不要な物体を CLIP[3] 等のマルチモーダル画像分類器で同定し、学習に使用する画像から削除することで（図 2）、再構成させる自由視点画像の最適化を試みる．

1.2 本研究の構成

本論文は次のように構成される．第一章では本研究の概要を説明した．第二章では主要な3次元再構成に触れつつ、現状の課題を述べる．第三章では提案手法を説明する．不要物を同定するアルゴリズムと、拡散モデルによる削除部の補完を行う手法を説明する．第四章では評価実験と考察を行う．

2 研究背景

2.1 関連研究

2.1.1 3次元再構成技術

3次元再構成とは、3次元空間における物体の形状や位置を再構成する技術である。SfM (Structure-from-Motion: 運動復元) [4] はその代表的な例である。SfM は、同一シーンを異なる視点から撮影した複数の画像から、3次元空間におけるシーンの構造 (Structure) と各画像を撮影したカメラの位置・姿勢 (Motion) を同時に推定する技術である。処理の流れとしては、まず各画像から特徴点 (SIFT や ORB などの特徴記述子) を検出し、異なる画像間で対応する特徴点をマッチングする。次に、対応点の情報を用いてカメラの内部パラメータと外部パラメータ (位置・姿勢) を推定し、三角測量により 3次元点群を復元する。最後に、バンドル調整 (Bundle Adjustment) と呼ばれる最適化手法により、再投影誤差を最小化することで、カメラパラメータと 3次元構造を同時に精密化する。SfM は、特別な計測機器を必要とせず、一般的なカメラで撮影した画像のみから 3次元モデルを構築できる点が大きな利点であり、フォトグラメトリやデジタルアーカイブ、地図作成などの幅広い分野で活用されている。

そのほかにも、ニューラルネットワークを用いて 3次元空間を表現する手法がある。NeRF[5] は、2020 年に Mildenhall らによって提案された、ニューラルネットワークを用いてシーンを連続的な関数として表現する技術である。同一シーンを異なる視点から撮影した複数の画像とカメラパラメータを用いて学習し、ボリュームレンダリングにより任意の視点から高品質な自由視点画像を生成することができる。NeRF の主な利点は、従来の点群ベースの手法と比較して、3次元空間を連続的な関数として表現することで、細部まで高品質な画像を生成できる点である。一方で、レンダリング時に各ピクセルごとにニューラルネットワークの推論が必要となるため、レンダリング速度が非常に遅く、リアルタイムでの自由視点ナビゲーションが困難であるという課題がある。

このレンダリングの遅さを解消したのが、2023 年に発表されたのが Kerbl らによって提案された 3D Gaussian Splatting (3DGS) [1] である。学習を進めながら生成の品質を高める点では NeRF と同一であるが、3次元空間を 3次元ガウス分布の集合として表現することが特徴である。各ガウス分布は、位置、共分散行列 (形状と向き)、不透明度、そして球状調和関数に基づく色情報をパラメータとして持つ。ポイントベースの α (アルファ) ブレンディングと NeRF スタイルのボリュームレンダリングは、本質的に同じ画像生成モデルを共有している。具体的には、ある光線 (レイ) に沿った色 C は、以下のボリュームレンダリングの式で与えられる：

$$C = \sum_{i=1}^N T_i (1 - \exp(-\sigma_i \delta_i)) c_i \quad \text{ここで} \quad T_i = \exp \left(- \sum_{j=1}^{i-1} \sigma_j \delta_j \right) \quad (1)$$

ここで、密度 σ 、透過率 T 、および色 c のサンプルが、間隔 δ_i で光線に沿って取得される。これは次のように書き換えることができる：

$$C = \sum_{i=1}^N T_i \alpha_i c_i \quad (2)$$

ただし、 $\alpha_i = (1 - \exp(-\sigma_i \delta_i))$ および $T_i = \prod_{j=1}^{i-1} (1 - \alpha_j)$ である。典型的なニューラルポイントベースのアプローチは、ピクセルに重なる N 個の順序付けられた点をブレンディングすることで、ピクセルの色 C を計算する：

$$C = \sum_{i \in N} c_i \alpha_i \prod_{j=1}^{i-1} (1 - \alpha_j) \quad (3)$$

ここで、 c_i は各点の色であり、 α_i は学習された「点ごとの不透明度」に、共分散 Σ を持つ 2 次元ガウス関数を評価して得られる値を掛け合わせることで求められる。

自由視点画像を生成する際、これらの 3D ガウス分布をカメラ平面にスプラッチング（射影）し、ハードウェアが高速に処理できるラスタライズ技術を利用してピクセル単位の色を合成する。これにより、NeRF と比較して画質を維持しつつ、学習時間およびレンダリング速度を大幅に短縮し、リアルタイムでの自由視点ナビゲーションを可能にした [1]。本研究の提案手法も、この高速な 3DGS を基盤技術として採用している。

2.1.2 セマンティックセグメンテーション

セマンティックセグメンテーションは、画像の各ピクセルをなんらか意味を持った領域に分割する技術のことである。一つの画像に対して一つのラベルを付与する画像分類問題や、画像内の物体を認識し、矩形で過酷む物体検出と比べると、セマンティックセグメンテーションは画像中のピクセルに対してラベルを付与することで、より細かい粒度での物体の分割を行うことができる（図 1）。

SAM2[6] はセマンティックセグメンテーションの代表的な例である。SAM2 は、従来のセマンティックセグメンテーション手法が特定の物体クラスに限定されていたり、動画シーケンスへの対応が困難であったりした課題を克服した画期的な手法であ

る。SAM2 の最大の特徴は、大規模データセットで学習された汎用的なセグメンテーションモデルを持ち、事前に学習した物体クラス以外の物体もセグメンテーションできる点である。さらに、画像だけでなく動画シーケンスにも対応し、時系列情報を活用することで、より一貫性のあるセグメンテーション結果を生成することができる。また、ユーザーからの点や矩形、テキストなどの多様な入力形式を受け付けることができる点も、従来手法と比較して大きな進歩であった。



図 1: コンピュータビジョンタスクの比較

2.1.3 映り込みに対応した自由視点画像生成技術

Tang らによって提案された DroneSplat[2] は、ドローンを用いた大規模な屋外環境における動的物体への耐性を高めた 3DGS[1] の拡張手法である。本手法は、Segment Anything Model v2 (SAM2) [6] を用いた適応的な動的物体マスキング (Adaptive dynamic-object masking) を特徴とする。

DroneSplat の学習プロセスは、2 段階の学習フェーズから構成される。第 1 段階 (Pre-training) では、SAM2 を用いて各学習画像 I_k ($k = 1, \dots, N$ はフレーム番号) からインスタンスレベルのセグメンテーションマスク $\mathcal{M}_k = \{M_k^1, M_k^2, \dots, M_k^{S_k}\}$ を取得する。ここで、 S_k はフレーム k におけるセグメント数である。

次に、3DGS の学習において、動的物体を含むセグメントを段階的に除外する適応的マスキングを適用する。具体的には、学習 iteration t における損失関数 $\mathcal{L}_t$ を以下のように定義する：

$$\mathcal{L}_t = \sum_{k=1}^N \sum_{p \in \mathcal{P}_k} w_t(p) \cdot \ell(\hat{I}_k(p), I_k(p)) \quad (4)$$

ここで、 $\hat{I}_k(p)$ はフレーム k のピクセル p におけるレンダリング結果、 $I_k(p)$ は正

解画像, $\ell(\cdot, \cdot)$ は L1 損失と SSIM 損失の組み合わせ, $\mathcal{P}_k$ はフレーム k の全ピクセル集合である. 重み $w_t(p)$ は, iteration t におけるピクセル p の動的物体マスク $\mathcal{M}_t^{dynamic}(p)$ に基づいて以下のように決定される:

$$w_t(p) = \begin{cases} 0 & \text{if } \mathcal{M}_t^{dynamic}(p) = 1 \\ 1 & \text{otherwise} \end{cases} \quad (5)$$

動的物体マスク $\mathcal{M}_t^{dynamic}$ は, 各 iteration において更新される. 初期 iteration では全セグメントを学習対象とするが, 学習が進むにつれて, 複数フレーム間で一貫性のない再構成誤差を示すセグメントを動的物体として同定し, 段階的に除外する. 具体的には, セグメント M_k^i の動的度合い D_k^i を以下の式で計算する:

$$D_k^i = \frac{1}{|M_k^i|} \sum_{p \in M_k^i} \frac{\ell(\hat{I}_k(p), I_k(p))}{\max_{q \in \mathcal{P}_k} \ell(\hat{I}_k(q), I_k(q))} \quad (6)$$

ここで, $|M_k^i|$ はセグメント M_k^i の画素数である. 動的度合いが閾値 $\tau_{dynamic}$ を超えるセグメントは動的物体として判定され, その後の学習から除外される.

第2段階 (Main training) では, 第1段階で得られた動的物体マスクを用いて, 動的物体を除外した画像に対して 3DGS を再学習する. これにより, 動的な不要物体を考慮しない高品質な 3D シーン再構成が可能となる.

評価実験では, 従来の 3DGS に対し, ドローン撮影時の再構成精度および視点合成品質の両面で有意な改善を示しつつ, GPU 上でのリアルタイムレンダリング性能も維持できることが報告されている (図 2).



(a) 3DGS[1] で作成
車が動いている場面を表現できない



(b) DroneSplat[2] で生成
動体を無視して表現できる

図 2: 動的シーンにおける自由視点画像生成の例

2.2 現状の課題

3 提案手法

3.1 不要物同定アルゴリズム

本節では，映り込みに対応した自由視点画像生成技術において，不要物を同定することを考える．本研究における不要物とは以下の2つである：

1. 動的な物体
2. 静止しているがユーザが不要と判断した物体

動的な物体の同定は，DroneSplat[2] で対応が行われている．しかし，静止しているかつユーザが不要と判断した物体を同定することはできない．また，DroneSplatにおける動的な物体の検出も学習画像によって間違いが起こることも多い（図3）




図3: 学習用画像には，動いている車両と背景が含まれている（図3a）．DroneSplat[2]によって動いていると判定されたオブジェクトを（図3b）に示す．動的な物体の物体漏れが発生する．また，動いていないはずの背景も動いていると誤判定されるケースもある．

本手法では，3DGS[1]の学習において，動的オブジェクトと静止オブジェクトを区別して不要物を同定する．動的オブジェクトは学習中の損失情報から検出し，静止オブジェクトは事前学習済みのセグメンテーションモデルを用いて検出する．両者の情報を統合することで，より包括的な不要物同定を実現する．

本手法の学習の流れを以下に示す：

1. **初期学習**: 元の画像データセットを用いて DroneSplat を学習し，動的オブジェクトのマスクを取得する（3.1.2 節）．
2. **オブジェクト検出**: SAM3 を用いてすべての車を検出する．
3. **マスクフィルタリング**: SAM3 の検出結果と動的オブジェクトのマスクを比較し，重複するオブジェクトを除外する（3.1.3 節）．
4. **インペインティング**: フィルタリング後の静止オブジェクトマスクに対して LaMa を適用し，不要物を除去した画像を生成する（3.1.4 節）．

5. **再学習**: インペインティング後の画像を用いて DroneSplat を再学習し、最終的な 3D シーン再構成を行う。

このフローにより、動的オブジェクトと静止オブジェクトの両方を効果的に除去し、高品質な 3D シーン再構成を実現する（図 4）。




図 4: 提案手法の全体フロー

3.1.1 動的オブジェクトの検出

動的オブジェクトは、3D Gaussian Splatting[1] の学習過程において、複数フレーム間で一貫性のない再構成誤差を示す領域として検出される。本手法では、DroneSplat[2] の学習アルゴリズムを拡張し、各フレームにおけるインスタンスレベルの損失分布を分析することで動的オブジェクトを同定する。

具体的には、学習開始から一定の iteration（本実験では 500 iteration）経過後、各フレームのレンダリング結果と正解画像との間の L1 損失および SSIM 損失を計算する。これらの損失を正規化し、以下の式で統合損失を算出する：

$$L_{combined} = \frac{4 \cdot L_{L1}^{norm} + L_{SSIM}^{norm}}{5} \quad (7)$$

ここで, L_{L1}^{norm} および L_{SSIM}^{norm} は, それぞれ L1 損失と SSIM 損失を 0-1 の範囲に正規化した値である.

次に, 各フレームに与えられたインスタンスセグメンテーションマスクを用いて, インスタンス単位での損失を集計する. インスタンス i の損失 L_i は, 以下の式で計算される:

$$L_i = \frac{\sum_{p \in M_i} L_{combined}(p)}{|M_i|} \quad (8)$$

ここで, M_i はインスタンス i のマスク領域, $|M_i|$ はその画素数である.

各インスタンスの損失値をヒートマップとして可視化し, 動的閾値 $T_{dynamic}$ を以下の式で決定する:

$$T_{dynamic} = \mu + \sigma + \alpha \cdot \sigma \cdot \frac{I_{max} - I_{current}}{I_{max}} \quad (9)$$

ここで, μ と σ はヒートマップの平均値と標準偏差, $I_{current}$ と I_{max} は現在の iteration と最大 iteration, α は調整パラメータである. この閾値により, 学習の進行に応じて動的オブジェクトの検出感度を調整する.

損失値が閾値を超えるインスタンスは動的オブジェクトとして判定され, そのマスクが除外対象として記録される. 学習の最終 iteration において, すべての学習フレームに対する除外マスクを保存する.

3.1.2 静止オブジェクトの検出とフィルタリング

静止オブジェクトの検出には, Segment Anything Model 3 (SAM3)[7] を用いる. SAM3 は, テキストプロンプト (本実験では "car") に基づいて動画シーケンス全体から対象オブジェクトを追跡・セグメンテーションする. 各フレームにおいて, 検出されたオブジェクトのマスク, バウンディングボックス, 信頼度スコアが出力される.

しかし, SAM3 は動的・静止を区別せずにすべての車を検出するため, 動的オブジェクトと静止オブジェクトを区別する必要がある. 本手法では, 3.1.2 節で検出された動的オブジェクトのマスクと SAM3 の検出結果を比較し, 重複するオブジェクトを除外する.

具体的には, SAM3 で検出された各オブジェクト o_j について, そのマスク $M_{SAM3}(o_j)$ と動的オブジェクトのマスク $M_{dynamic}$ との重複率 $R_{overlap}$ を以下の式で計算する:

$$R_{overlap}(o_j) = \frac{|M_{SAM3}(o_j) \cap M_{dynamic}|}{|M_{SAM3}(o_j)|} \quad (10)$$

ここで、 $|M_{SAM3}(o_j) \cap M_{dynamic}|$ は重複領域の画素数、 $|M_{SAM3}(o_j)|$ は SAM3 オブジェクトの総画素数である。

重複率が閾値 $T_{overlap}$ （本実験では 0.5）を超える場合、そのオブジェクトは動的オブジェクトとして既に検出されていると判定し、SAM3 の検出結果から除外する。これにより、静止オブジェクトのみが残る。

3.1.3 不要物の除去

同定された不要物（動的オブジェクトおよび静止オブジェクト）は、画像インペインティング技術を用いて除去する。本手法では、Large Mask Inpainting (LaMa)[8] を使用する。

静止オブジェクトのマスクは、境界の拡張処理を適用してからインペインティングを行う。具体的には、形態学的な膨張処理（カーネルサイズ 15 ピクセル）により、マスクの境界を拡張し、より自然な補完結果を得る。

各オブジェクトは順次処理され、最終的にすべての不要物が除去された画像が生成される。この画像を 3D Gaussian Splatting の学習データとして使用することで、動的オブジェクトの影響を受けない高品質な 3D シーン再構成が可能となる。

3.2 拡散モデルによる削除部の補完

4 評価実験と考察

4.1 データセット

4.2 不要物同定アルゴリズムの評価実験

4.2.1 SAM2 と CLIP による不要物同定

まず不要物同定アルゴリズムとして，SAM2 と CLIP を用いた不要物同定を評価する．

4.2.2 SAM3 による不要物同定

次に，SAM3 を用いた不要物同定を評価する．

4.3 拡散モデルによる削除部の補完の評価実験

4.3.1 学習用画像中に一貫性を持たせた拡散モデルの有効性の検証

4.3.2 動的な不要物の除去における拡散モデルの必要性の検証

映り込みに対応した自由視点画像生成技術の DroneSplat[2] においては，動的物体を学習から削除している．一方

5 おわりに

おわりにです。いったんいかに使えそうなものを避難させておくこととする。

5.1 結論

5.2 今後の課題

課題は

参考文献

- [1] Bernhard Kerbl, Georgios Kopanas, Thomas Leimkühler, and George Drettakis. 3d gaussian splatting for real-time radiance field rendering. *ACM Transactions on Graphics*, 42(4), July 2023.
- [2] Jiadong Tang, Yu Gao, Dianyi Yang, Liqi Yan, Yufeng Yue, and Yi Yang. Dronesplat: 3d gaussian splatting for robust 3d reconstruction from in-the-wild drone imagery, 2025.
- [3] Alec Radford, Jong Wook Kim, Chris Hallacy, Aditya Ramesh, Gabriel Goh, Sandhini Agarwal, Girish Sastry, Amanda Askell, Pamela Mishkin, Jack Clark, Gretchen Krueger, and Ilya Sutskever. Learning transferable visual models from natural language supervision. *CoRR*, abs/2103.00020, 2021.
- [4] Noah Snavely, Steven M. Seitz, and Richard Szeliski. Photo tourism: Exploring photo collections in 3d. In *ACM SIGGRAPH*, pages 835–846, 2006.
- [5] Ben Mildenhall, Pratul P. Srinivasan, Matthew Tancik, Jonathan T. Bar-

表 1: Simingshan データセットにおける各手法の性能比較

Method	Simingshan		
	PSNR↑	SSIM↑	LPIPS↓
NeRF[5]	19.07	0.417	0.267
3DGS[1]	19.68	0.476	0.254
DroneSplat[2]	22.76	0.759	0.152
Ours	22.35	0.744	0.174

- ron, Ravi Ramamoorthi, and Ren Ng. Nerf: Representing scenes as neural radiance fields for view synthesis, 2020.
- [6] Nikhila Ravi, Valentin Gabeur, Yuan-Ting Hu, Ronghang Hu, Chaitanya Ryali, Tengyu Ma, Haitham Khedr, Roman Rädle, Chloe Rolland, Laura Gustafson, Eric Mintun, Junting Pan, Kalyan Vasudev Alwala, Nicolas Carion, Chao-Yuan Wu, Ross Girshick, Piotr Dollár, and Christoph Feichtenhofer. Sam 2: Segment anything in images and videos. *arXiv preprint arXiv:2408.00714*, 2024.
- [7] Nicolas Carion, Laura Gustafson, Yuan-Ting Hu, Shoubhik Debnath, Ronghang Hu, Didac Suris, Chaitanya Ryali, Kalyan Vasudev Alwala, Haitham Khedr, Andrew Huang, Jie Lei, Tengyu Ma, Baishan Guo, Arpit Kalla, Markus Marks, Joseph Greer, Meng Wang, Peize Sun, Roman Rädle, Triantafyllos Afouras, Effrosyni Mavroudi, Katherine Xu, Tsung-Han Wu, Yu Zhou, Liliane Momeni, Rishi Hazra, Shuangrui Ding, Sagar Vaze, Francois Porcher, Feng Li, Siyuan Li, Aishwarya Kamath, Ho Kei Cheng, Piotr Dollár, Nikhila Ravi, Kate Saenko, Pengchuan Zhang, and Christoph Feichtenhofer. Sam 3: Segment anything with concepts, 2025.
- [8] Roman Suvorov, Elizaveta Logacheva, Anton Mashikhin, Anastasia Remizova, Arsenii Ashukha, Aleksei Silvestrov, Naejin Kong, Harshith Goka, Kiwoong Park, and Victor Lempitsky. Resolution-robust large mask inpainting with fourier convolutions. *arXiv preprint arXiv:2109.07161*, 2021.